

Modujo 1B 预训练过程报告

PUBLIC RESEARCH REPORT · MODUJO

下载 PDF 版本

模型概览

本次发布的是 Modujo-1B-A0.75B 预训练基础模型。其中，1B 表示模型的总体规模，A0.75B 表示处理每个 token 时实际参与计算的参数规模。模型支持中英文文本续写和基础知识补全。当前版本尚未经过指令微调，更适合用于继续训练、能力评估和研究实验，不建议直接作为聊天助手使用。模型权重可从 Hugging Face 的 [`pretrain/Modujo-1B-A0.75B/`](#) 获取。

最值得关注的数字	实际情况
训练硬件	后期主要使用 4 × NVIDIA H100 80GB；单卡训练显存约 70–75 GiB
模型	1B 总规模、A0.75B 激活规模、36 层；每层 8 个专家、每个 token 选择 2 个
数据	第一阶段约 50.8 万条长文本片段；继续训练阶段约 1,033 万条记录
训练时间	第一阶段从 2026-09-16 开始；继续训练从 09-17 开始，主要大批次训练在 09-21 至 09-27；最后一次长续跑日志记录约 5 天 9 小时
实际训练长度	最长 2,048 token/条；模型配置的 32K 位置上限不代表这轮已训练验证了 32K 效果

训练路线：为什么分两段

第一段是通用预训练。模型在中英文文本上学习句子结构、常见知识和基本续写。训练集整理成约 50.8 万条、每条接近 2,048 token 的片段。训练日志里，loss 从第 1 步的约 12.46 降到第 18,000 步的约 4.53。最终产物的后续训练链从这个约 18,000 步的权重出发；另有继续训练到 19,300 步的通用权重，但它不是最终权重的直接前身。

第二段是继续预训练。训练混合了 MiniMind 文本，以及 Amazon ESCI、Wayfair WANDS 的商品资料。后两者主要提供标题、品牌、描述和属性等原始文本；它们是这轮语料的组成部分，并非模型用途的唯一目标。经数据处理后，训练载入约 1,033 万条记录，平均约 211 token/条；按记录数和平均长度估算，整轮数据约 21.8 亿 token。训练到 78,900 步，对应计划一轮的约 97.8%。这是数据规模估算，并非去重后的独立 token 数。

这条训练链在 9 月中下旬有多次续跑。最新权重于 2026-09-27 23:16 (UTC+8, 文件时间) 保存；最后的训练日志还到 78,940 步，但没有更晚的完整模型权重。因此评估和后续转换都应明确指向 78,900 步权重，不要把日志步数当成产物步数。

硬件和结构：哪些选择影响了这次训练


后期大批次阶段使用 4 张 H100 80GB，BF16 精度。每卡每次输入 4 条，累积 8 次梯度后更新一次，实际全局 batch 为 128 条/步。每条最多 2,048 token；因为原始记录长短差异很大， $128 \times 2,048$ 只是每步的长度上限，不是实际处理的 token 数。最后一段续跑平均约 6.7 秒/步，单卡显存日志约 70–75 GiB。

模型采用 36 层混合专家结构（MoE），总规模为 1B，每个 token 的激活规模约为 A0.75B。每层有 8 个专家，每个 token 只选 2 个专家；注意力层按“3 层 GDN 线性注意力 + 1 层常规注意力”重复排列。当前权重尚未加入 QSA 稀疏索引器；名称中的 `qwen_sparse_attention` 层在这一阶段按常规注意力模式运行。

训练还加入了 MoE 专家负载均衡辅助损失（aux loss），系数为 0.001。它持续约束路由器，避免大量 token 长期集中到少数专家。aux loss 从早期约 1.998 缓慢降至后期约 1.996–1.997，说明模型持续优化这一均衡目标；单看这个汇总值，还不能证明每个专家的负载都完全均匀。

本轮实际采用 2,048 token 训练长度，重点仍是学习文本的统计规律。它不能据此证明长上下文能力，也不能让模型自动掌握稳定的问答和指令遵循：这些能力需要单独的数据与评估。

主要指标：训练进展与实际效果



上图 A、B 来自继续预训练日志：loss 由约 4.7 降至约 3.1，token 准确率由约 28% 升至约 45%。C 是 MoE 的 aux loss，缓慢下降，反映专家均衡目标仍在被优化。浅线是原始记录，深线按约 1,000 步平滑；红色虚线标出已保存的 78,900 步权重。这些都是训练指标，不能当作独立测试成绩。第一阶段的 loss 约 4.53，因数据分布不同，不与这里的 3.1 直接比较。

D 用同一批 16 条新写短文本对比训练早期和最终发布权重。这里的逐词损失越低越好：中文通用 6.19 → 5.99、中文商品文本 5.86 → 5.47、英文商品文本 4.18 → 4.10；英文通用 5.19 → 5.21，没有改善。可以看到中文两类都有进步，英文表现有分化。这组样本太小，只能作为快速检查，不能作为正式泛化结论。

生成案例：局部能力已有，长输出仍不稳

下面案例均来自 78,900 步权重的固定提示词测试，最多生成 64 个 token。除标注“采样”的一例外，都使用贪心解码。表中摘录关键片段；完整输出见文末记录。

Good case	输入	实际输出摘录	说明
中文事实	中国的首都是	哪里？中国的首都是北京。	事实正确，但接成了问答，而非直接补全。
简单算术	问：1加1等于多少？\n答：	加1等于2。	给出正确答案；后面又自行转到质数话题。
英文常识	The sun rises in the east and	sets in the west.	首句补全正确；继续生成开始重复。
日常续写（采样）	今天天气很好，我决定	去公园散步。我决定去公园散步。公园里有许多美景……	开头连贯，与语境相关。

Bad case	输入	实际输出摘录	问题
日常续写	今天天气很好，我决定	我去了公园，看到了很多美丽的花朵和树木。连续重复多次	开头合理，但无法维持段落质量。
简单解释	植物需要阳光，是因为	植物需要阳光才能生长，因此它们需要阳光才能生长。	循环改写问题，没有解释光合作用。
商品文本	这款无线耳机支持蓝牙连接……产品特点：	无线连接支持蓝牙连接，支持蓝牙连接，支持蓝牙连接。	反复复述，缺少新信息。
聊天指令	你好，请用中文介绍一下自己。	A:\n \n \n \n	使用聊天模板后没有回答，陷入表格符号。
身份问答	问：你好，你是谁？\n答：	我是来自阿里云的超大规模语言模型，我叫通义千问。	冒认其他模型身份。

这些案例说明模型具备短距离的文本续写和部分知识补全能力，但很难稳定地维持整段回答。可能原因是预训练主要让模型预测下一个词，学到的文本模式未必等于按用户需求回答。贪心解码可能放大重复，身份冒认可能来自训练文本中的问答模式迁移。这些都是基于现象的推测，尚未做消融确认。

下一步重点

接下来计划沿三个方向分别验证，所有实验都从当前预训练基础模型出发，并使用独立目录保存，避免不同训练路线相互混淆。

SFT：提升指令理解和回答质量

使用高质量中英文指令数据进行监督微调，让模型从“续写文本”进一步转向“理解要求并完成任务”。评估重点包括指令遵循、回答完整性、重复控制、事实准确性和多轮对话稳定性。

QSA：探索更高效的长上下文处理

为常规注意力层加入 QSA 稀疏索引器，先单独训练索引能力，再进行联合训练。实验将同时比较长文本任务效果、推理速度和显存占用，确认效率提升是否会带来明显的质量损失。

Looped Transformer：探索层复用

让部分 Transformer 层在一次前向计算中重复使用，以较少的独立参数获得更深的计算过程。实验将与普通模型对照，重点观察训练稳定性、生成质量、计算开销，以及参数复用是否带来实际收益。